Proyecto Final - Documentación del modelado de datos
Presentado Por – Grupo 4: Andrea Correa, Juan Sebastián Calderon, Paula Guarín
Visualización y Storytelling
Base: *Global Power Plant Database*

Este documento describe paso a paso el proceso de modelado y preparación de datos realizado en Python para la posterior construcción del dashboard en Looker Studio.

1. Cargar la base de datos

Se cargó el archivo original 'global_power_plant_database.csv' utilizando la librería pandas. Esta base contiene información mundial sobre plantas de energía.

```
[1]: #Librerías
     import pandas as pd
```

```
[3]: #Cargar base de datos relacionada con las plantas de energía a nivel mundial

     df = pd.read_csv("global_power_plant_database.csv")
     df.head()
```

```
C:\Users\paula\AppData\Local\Temp\ipykernel_16828\4078533440.py:3: DtypeWarning: Columns (10) have mixed types. Specify dtype option on import or set lo
w_memory=False.
  df = pd.read_csv("global_power_plant_database.csv")
```

[3]:

	country	country_long	name	gppd_idnr	capacity_mw	latitude	longitude	primary_fuel	other_fuel1	other_fuel2	...	estimated_generation_gwh_2013	e
0	AFG	Afghanistan	Kajaki Hydroelectric Power Plant Afghanistan	GEODB0040538	33.0	32.322	65.1190	Hydro	NaN	NaN	...	123.77	
1	AFG	Afghanistan	Kandahar DOG	WKS0070144	10.0	31.670	65.7950	Solar	NaN	NaN	...	18.43	
2	AFG	Afghanistan	Kandahar JOL	WKS0071196	10.0	31.623	65.7920	Solar	NaN	NaN	...	18.64	
3	AFG	Afghanistan	Mahipar Hydroelectric Power Plant Afghanistan	GEODB0040541	66.0	34.556	69.4787	Hydro	NaN	NaN	...	225.06	
4	AFG	Afghanistan	Naghlu Dam Hydroelectric Power Plant Afghanistan	GEODB0040534	100.0	34.641	69.7170	Hydro	NaN	NaN	...	406.16	

5 rows × 36 columns

2. Entendimiento de variables iniciales de la base

A continuación, se presentan las principales variables originales de la base de datos Global Power Plant Database, incluyendo su tipo y una breve descripción.

Variable original (inglés)	Tipo	Descripción
country	Texto	Código ISO del país donde se ubica la planta.
country_long	Texto	Nombre completo del país.
name	Texto	Nombre de la planta de energía.
gppd_idnr	Texto	Identificador único de la planta en la base de datos.
capacity_mw	Numérico	Capacidad instalada de la planta en megavatios (MW).
latitude	Numérico	Coordenada geográfica de latitud.
longitude	Numérico	Coordenada geográfica de longitud.
primary_fuel	Texto	Tipo principal de combustible utilizado.
commissioning_year	Numérico	Año en que la planta inició operaciones.
generation_gwh	Numérico	Generación eléctrica reportada en GWh.
estimated_generation_gwh_2013-2017	Numérico	Generación eléctrica estimada por año en GWh (2013 a 2017).
owner	Texto	Entidad o empresa propietaria de la planta.

3. Variables después del modelado

Con el objetivo de mejorar la claridad del análisis y facilitar la interpretación para el público general, se renombraron las principales variables al español.

```
[5]: #Renombrar columnas a español para mejor entendimiento

df = df.rename(columns={
    'country': 'codigo_pais',
    'country_long': 'pais',
    'primary_fuel': 'combustible_principal',
    'capacity_mw': 'capacidad_mw',
    'latitude': 'latitud',
    'longitude': 'longitud',
    'commissioning_year': 'anio_puesta_en_marcha',
    'generation_gwh': 'generacion_gwh',
    'owner': 'propietario'
})

df.head()
```

[5]:

	codigo_pais	pais	name	gppd_idnr	capacidad_mw	latitud	longitud	combustible_principal	other_fuel1	other_fuel2	...	estimated_generation_gw
0	AFG	Afghanistan	Kajaki Hydroelectric Power Plant Afghanistan	GEODB0040538	33.0	32.322	65.1190	Hydro	NaN	NaN	...	
1	AFG	Afghanistan	Kandahar DOG	WKS0070144	10.0	31.670	65.7950	Solar	NaN	NaN	...	
2	AFG	Afghanistan	Kandahar JOL	WKS0071196	10.0	31.623	65.7920	Solar	NaN	NaN	...	
3	AFG	Afghanistan	Mahipar Hydroelectric Power Plant Afghanistan	GEODB0040541	66.0	34.556	69.4787	Hydro	NaN	NaN	...	
4	AFG	Afghanistan	Naghlu Dam Hydroelectric Power Plant Afghanistan	GEODB0040534	100.0	34.641	69.7170	Hydro	NaN	NaN	...	

5 rows × 36 columns

4. Limpieza de datos

Esta sección describe el procedimiento de una depuración inicial que se realizó al conjunto de datos con el fin de garantizar consistencia y calidad en el análisis,

- **Valores duplicados:**
  Se eliminaron registros duplicados para evitar sobreestimaciones en los cálculos.

```
#Eliminar duplicados
df = df.drop_duplicates()
```

- **Valores nulos:**
  Se identificaron valores nulos en la variable de capacidad instalada, eliminando aquellos registros sin información relevante para el análisis energético.

```
[23]: #Validar valores nulos
df.isnull().sum()
```

```
[23]: codigo_pais                        0
pais                                     0
name                                     0
gppd_idnr                                0
capacidad_mw                             0
latitud                                  0
longitud                                 0
combustible_principal                    0
other_fuel1                          32992
other_fuel2                          34660
other_fuel3                          34844
anio_puesta_en_marcha                17489
propietario                          14068
source                                  15
url                                     18
geolocation_source                     419
wepp_id                              18702
year_of_capacity_data                20049
generation_gwh_2013                  28519
generation_gwh_2014                  27710
generation_gwh_2015                  26733
generation_gwh_2016                  25792
generation_gwh_2017                  25436
generation_gwh_2018                  25299
generation_gwh_2019                  25277
generation_data_source               23536
estimated_generation_gwh_2013        18816
estimated_generation_gwh_2014        18433
estimated_generation_gwh_2015        17886
estimated_generation_gwh_2016        17366
```

```
#Eliminar filas sin capacidad
df = df[df['capacidad_mw'].notnull()]
```

- **Plantas no operativas:**
  Se validó que la capacidad no contuviera valores menores o iguales a cero, ya que no representan plantas operativas.

```
#Eliminar capacidad inválida
df = df[df['capacidad_mw'] > 0]
```

5. Creación de nuevas variables

Con el objetivo de enriquecer el análisis, se generaron nuevas variables a partir de las originales. Estas transformaciones permiten simplificar el análisis visual posterior.

- **Tipo energía:**
  Se clasificó cada planta en 'Renovable' o 'No Renovable' según su combustible principal, permitiendo comparar la transición energética.

```
#Clasificar renovable vs no renovable
renovables = ['Solar', 'Wind', 'Hydro', 'Geothermal', 'Biomass']

df['tipo_energia'] = df['combustible_principal'].apply(
    lambda x: 'Renovable' if x in renovables else 'No Renovable'
)
```

- **Capacidad productiva:**
  Se convirtió la capacidad de megavatios (MW) a gigavatios (GW) para facilitar la interpretación.

```
#Convertir capacidad a gigavatios
df['capacidad_gw'] = df['capacidad_mw'] / 1000
```

- **Antigüedad planta de energía:**
  Se creo una nueva variable para determinar la antigüedad de cada planta.

```
#Crear antigüedad de la planta
df['antiguedad_planta'] = 2026 - df['anio_puesta_en_marcha']
df['antiguedad_planta'] = df['antiguedad_planta'].fillna(0)
```

- **Transformación de las variables de tiempo:**
  Las columnas de generación estimada por año (2013–2017) se encontraban en formato ancho, lo que dificulta el análisis temporal. Por esta razón, se utilizó la función melt() de pandas para convertir la estructura a formato largo, generando dos columnas nuevas: 'anio' y 'generacion_estimada_gwh'. Esta transformación permite analizar tendencias anuales y construir gráficos de línea de tiempo en Looker Studio. Tras la transformación, se eliminaron filas sin datos de generación estimada, ya que no aportaban valor al análisis temporal. Este paso permitió mantener coherencia en los cálculos agregados por año y evitar distorsiones en los gráficos.

```python
#Análisis temporal
#Detectar automáticamente columnas de generación estimada
columnas_anios = [col for col in df.columns if 'estimated_generation_gwh_' in col]

df_largo = df.melt(
    id_vars=[
        'codigo_pais',
        'pais',
        'tipo_energia',
        'capacidad_gw',
        'latitud',
        'longitud',
        'anio_puesta_en_marcha',
        'antiguedad_planta',
        'propietario'
    ],
    value_vars=columnas_anios,
    var_name='anio',
    value_name='generacion_estimada_gwh'
)

df_largo['anio'] = df_largo['anio'].str.extract('(\d+)')
df_largo['anio'] = df_largo['anio'].astype(int)

df_largo = df_largo[df_largo['generacion_estimada_gwh'].notnull()]
```

6. Selección de columnas finales

Para optimizar el rendimiento del dashboard, se conservaron únicamente las columnas necesarias para la visualización: código de país, nombre del país, tipo de energía, capacidad en GW, coordenadas geográficas, año y generación estimada, año puesto en marcha de la planta, antigüedad de la planta y propietario. La reducción de columnas permite disminuir el tamaño del archivo y mejorar la velocidad de carga en Looker Studio.

```python
#Seleccionar solo columnas finales necesarias para análisis
columnas_finales = [
    'codigo_pais',
    'pais',
    'tipo_energia',
    'capacidad_gw',
    'latitud',
    'longitud',
    'anio',
    'generacion_estimada_gwh',
    'anio_puesta_en_marcha',
    'antiguedad_planta',
    'propietario'
]

df_optimizado = df_largo[columnas_finales]
```

```python
#Validar df final
df_optimizado.head()
```

	codigo_pais	pais	tipo_energia	capacidad_gw	latitud	longitud	anio	generacion_estimada_gwh	anio_puesta_en_marcha	antiguedad_planta	propietario
0	AFG	Afghanistan	Renovable	0.033	32.322	65.1190	2013	123.77	NaN	0.0	NaN
1	AFG	Afghanistan	Renovable	0.010	31.670	65.7950	2013	18.43	NaN	0.0	NaN
2	AFG	Afghanistan	Renovable	0.010	31.623	65.7920	2013	18.64	NaN	0.0	NaN
3	AFG	Afghanistan	Renovable	0.066	34.556	69.4787	2013	225.06	NaN	0.0	NaN
4	AFG	Afghanistan	Renovable	0.100	34.641	69.7170	2013	406.16	NaN	0.0	NaN

7. Exportación de la base de datos

Finalmente, la base de datos limpia y transformada se exportó en formato CSV. Este archivo fue cargado en Google Sheets y posteriormente conectado a Looker Studio.

Descargar de base en Python:

```python
#Crear y guardad nuevo archivo
df_optimizado.to_csv("plantas_energia_limpio.csv", index=False)
print("Filas:", df_optimizado.shape[0])
print("Columnas:", df_optimizado.shape[1])
```

```
Filas: 100381
Columnas: 11
```

Cargar de base en Looker Studio: